




**LEARNING ANALYTICS RECEPTEN**  
METHODIEK EN VERANTWOORDING



*Auteurs: Stefan Voeten & Danique van den Bergh*  
*Adviseurs: Paul Vermeulen & Amy Franken*

*Copyright © Q-Sense 2021*

## Inhoudsopgave

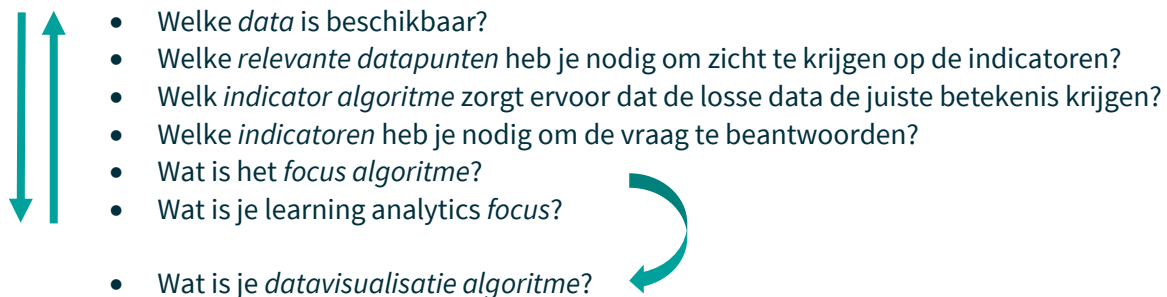
Inleiding.....	4
Focus .....	5
Indicatoren.....	5
Focus algoritme.....	7
Relevante datapunten en indicator algoritme.....	8
Datavisualisatie algoritme.....	13
Verdere overwegingen.....	15
Literatuur .....	16

## Inleiding

Om learning analytics toe te passen heb je meer nodig dan een grote bak met data. Data op zichzelf heeft namelijk geen context. Om betekenis te geven aan data heb je een learning analytics recept nodig. Wat is dat? Een recept is een verzameling regels/afspraken om met gebruik van data tot een onderwijskundige uitspraak te komen via learning analytics (Van Dompsele & Manderveld/SURF, 2016). Dat klinkt ingewikkeld. Om dit te verduidelijken kun je een learning analytics recept goed vergelijken met een recept om een gerecht te koken. Als je bijvoorbeeld chili con carne wil maken heb je meer nodig dan gehakt, tomatensaus en paprika. De ingrediënten op zichzelf zijn niet genoeg: je hebt een recept nodig om de benodigde ingrediënten te selecteren, de juiste hoeveelheden te verzamelen en deze vervolgens op de juiste manier te combineren. Bij learning analytics is het niet anders. De data krijgt betekenis door deze via een recept (een verzameling regels, afspraken en formules) te combineren. Uiteindelijk kom je dan tot je chili con carne, oftewel de learning analytics vraag die je wilt beantwoorden.

Maar hoe maak je dan precies zulke learning analytics recepten? In dit document wordt dat proces stap voor stap uitgelegd. Om dit concreet te maken wordt het voorbeeld van het recept 'lijst uitvalrisico' uit de Q-Monitor gebruikt. Daarmee is dit document niet alleen een advies van Q-Sense hoe je het maken van learning analytics recepten kunt aanpakken, maar tegelijkertijd ook een verantwoording en uitleg van de recepten in de Q-Monitor.

De volgende stappen worden hieronder besproken:



De vragen die hierboven staan beschreven vormen de leidraad van het proces waar je doorheen loopt. Maar zoals de pijlen ernaast aangeven: je hoeft niet altijd bovenaan te beginnen. Je kunt ook onderaan beginnen. En soms doorloop je de vragen ook in een andere volgorde, of ga je soms meerdere keren terug naar een eerdere vraag. Dit alles zal hieronder duidelijk worden.

## Focus

In dit voorbeeld beginnen we met onszelf af te vragen wat de learning analytics *focus* is: welke vraag wil je beantwoorden met behulp van data? In dit geval is de vraag die wij willen beantwoorden: *welke leerlingen lopen risico op uitval, en waarom?*

Daarmee is in dit voorbeeld de learning analytics focus: uitvalrisico.

## Indicatoren

De volgende vraag die we ons moeten stellen is: welke *indicatoren* heb je nodig om de vraag te beantwoorden? Om dit te onderzoeken kijken we naar verschillende gebieden. Zo raadplegen we wetenschappelijke literatuur over dit onderwerp, kijken we naar wat docenten in de onderwijspraktijk belangrijk vinden, en houden we rekening met de praktische mogelijkheden: is bepaalde data bijvoorbeeld wel beschikbaar?

Een eerste indicator kunnen de scores zijn. In de praktijk wordt er nog steeds vaak naar scores gekeken: een student die over het algemeen laag scoort lijkt meer kans te hebben om het niet te halen en uit te vallen dan een student die over het algemeen hoger scoort. Ook in de wetenschappelijke literatuur (Marbouti et al., 2016) blijkt dit een belangrijke indicator.

Maar om scores te kunnen krijgen moeten studenten ook dingen afronden. Opdrachten maken, assessments inleveren, theorie bekijken etc. Iedere leeractiviteit die men afrondt geeft aan dat de student bezig is met de stof. Aangezien dit ook in onderzoek terugkomt als een belangrijke indicator (Macfadyen & Dawson, 2009; Atherton et al., 2017; Shukor et al., 2014; Douglas & Alemanne, 2007) nemen wij afronding ook mee als indicator.

Het is ook belangrijk om te weten of studenten überhaupt aanwezig zijn. In eerste instantie gaat het hierbij dan om aanwezigheid in de klas. Een student die nooit op komt dagen heeft over het algemeen minder kans om te slagen. Maar hier lopen we ook tegen een limitatie in de praktijk op: hoewel docenten vaak wel aanwezigheid registreren, komt deze data niet altijd juist in systemen terecht of is het door technische zaken niet mogelijk deze data in te zien. Hierdoor komt het in de praktijk vaak voor dat deze data niet beschikbaar is in combinatie met andere data. Daarom is aanwezigheid in de klas niet in dit recept meegenomen als indicator. Dit is een voorbeeld waarbij we teruggaan naar de vraag bovenaan: welke data is beschikbaar? Dit geeft ook aan dat als men deze data toch wil meenemen het belangrijk is om te controleren wat ervoor nodig is om deze data beschikbaar te maken en dat eerst te regelen.

Wij focussen ons nu op wat we wel kunnen zien qua deelname: niet de aanwezigheid in de klas, maar de aanwezigheid online. Zeker bij cursussen waar studenten regelmatig online zaken moeten of kunnen inzien en/of inleveren is het een eerste vereiste dat men ook inlogt. Dit blijkt ook uit de literatuur. Bij het onderzoeken van uitvalrisico zijn er vele studies die beginnen bij het kijken naar inloggedrag (Jones, 2009; Beer et al., 2010; Dawson & McWilliam 2008; Shukor et al., 2014). Logisch, want zonder in te loggen kun je ook geen scores krijgen of dingen afronden. Daarom is inloggedrag voor ons de volgende indicator.

Een ander aandachtspunt voor studenten dat door docenten – en in academische literatuur (Jovanovic et al., 2019; Boroujeni et al., 2016) wordt aangegeven als een belangrijke factor is planning. Sommige studenten hebben wel de inhoudelijke kwaliteiten, maar hebben niet de

vaardigheden om op eigen verantwoordelijkheid de juiste planning samen te stellen om de cursus tot een goed eind te brengen. Daarom willen docenten vaak meer informatie over wanneer studenten dingen doen. Als men een blik werpt op de data zien we daar deadlines. Aan de hand daarvan kunnen we bekijken of studenten dingen vaak te laat inleveren of dat ze altijd mooi op tijd zijn. Studenten die vaker te laat zijn met inleveren hebben wellicht meer kans op uitval. Deze indicator noemen we inlevergedrag.

Ook de inlogdata kunnen meer informatie verschaffen over de planning van studenten. We kunnen immers zien wanneer iemand inlogt. Verschillende onderzoeken tonen ook aan dat het moment van inloggen belangrijk is (Jivet, 2016; Jovanovic et al., 2019; Boroujeni et al., 2016): studenten die elke week regelmatig aan de cursus werken hebben over het algemeen iets meer kans van slagen dan studenten die bijvoorbeeld alles in de laatste week doen. Het kan dus erg nuttig zijn om te zien of iemand elke week regelmatig inlogt, of juist heel onregelmatig inlogt. Inlog regelmaat blijkt ook een belangrijke indicator.

In veel academische literatuur komt naar voren dat ook communicatie een belangrijke indicator kan zijn (Morris et al., 2005; Douglas & Alemanne, 2007; Shukor et al., 2014; Macfadyen & Dawson, 2009). Hiermee wordt dan bijvoorbeeld bedoeld het aantal berichten dat iemand online post. Maar deze indicator blijkt in onze context minder nuttig. Dit omdat deze studies vooral in een context zijn uitgevoerd van MOOCS (een massive open online course, een cursus met massale deelname waarbij het cursusmateriaal wordt verspreid over het web), terwijl onze context vaker een (soms (deels) klassikale) cursus uit een opleiding is met meer vaste startmomenten en meer begeleiding van een docent. Dit betekent ook dat in deze context vaak minder gebruikt wordt gemaakt van berichten posten, terwijl dit in MOOCS vaak een essentieel onderdeel is. Hierdoor is communicatie voor onze context niet alleen minder belangrijk, maar ontbreekt deze data ook vaak. Hierdoor laten wij de indicator communicatie weg uit ons recept.

Maar een andere – en laatste – indicator die wél nuttig kan zijn in onze context is reflectiescores. Onderwijsorganisaties willen steeds vaker een breder beeld van de student dan alleen harde scores, men wil ook kijken naar soft skills en het bredere metacognitieve of sociaal-emotionele welzijn van de student. Als een student zich immers niet goed voelt in de cursus – ze zijn minder gemotiveerd, vinden het niet leuk of niet belangrijk – kan dat ook een hogere kans op uitval met zich meebrengen. Omdat dit ook in de literatuur lijkt te worden bevestigd (McKenney & Mor, 2015; Snijders, 2020) wordt ook reflectie een indicator in ons recept voor uitvalrisico.

## Focus algoritme

Nu we onze focus (uitvalrisico) en onze zes indicatoren (inloggedrag, inlogregelmaat, punctualiteit, score, afronding, reflectie) hebben is het tijd om te kijken wat het *focus algoritme* moet zijn. Dit betekent simpelweg: hoe zwaar moet iedere indicator wegen om aan te geven dat iemand risico loopt op uitval?


De belangrijkste indicator is inloggedrag. Als iemand immers niet inlogt kunnen er ook geen scores, afronding, punctualiteit etc. worden ingezien. Het begint dus bij inloggen. Deze indicator tellen we voor 30% mee voor het uitvalrisico. Maar dat inloggen belangrijk is, betekent niet dat inlog regelmaat daarmee de volgende meest belangrijke indicator is. Want hoewel regelmatigheid iemands kans op succes kan verhogen, kan het best zijn dat het voor sommige studenten beter past om juist zoveel mogelijk in de laatste weken te doen; elke student heeft een eigen leerstijl. Daarom weegt deze indicator slechts 10%.

Omdat punctualiteit een soortgelijke indicator is – over planning – die wel belangrijk is om mee te wegen maar niet per se doorslaggevend hoeft te zijn nemen we voor deze indicator dezelfde weging: 10%.

Wat is dan wel de tweede belangrijkste indicator? Dat wordt afronding. Het is namelijk zeer belangrijk dat iemand deelneemt aan de cursus. Zonder afronding is er geen sprake van een actieve deelname. Los daarvan kun je zonder afronding – wederom – geen data krijgen op andere indicatoren zoals reflectie, punctualiteit en score. Afronding telt voor 25% mee in het uitvalrisico.

Bij de weging voor score nemen we 20%. Dit doen we omdat zowel uit de literatuur als de praktijk blijkt dat deze misschien niet zo belangrijk is als deelname (afronding en inloggedrag), maar wel belangrijker dan bijvoorbeeld punctualiteit. Als iemand in de cursus namelijk alleen maar lage scores haalt, is dat wat kan bepalen – zeker omdat veel cursussen worden beoordeeld op cijfers – of iemand een hoge kans op uitvallen heeft of niet.

De laatste indicator die we dan nog hebben is reflectie. Deze willen we wel meetellen, want als iemand niet gemotiveerd is kan dat een invloed hebben op diens uitvalrisico. Maar tegelijkertijd zijn de andere indicatoren belangrijker om te bepalen of iemand daadwerkelijk gaat uitvallen. Iemand kan immers niet zo gemotiveerd zijn, maar als ze het niveau goed aankunnen wel gewoon de cursus halen. De indicator reflectie weegt daarom 5% voor het uitvalrisico.




Daarmee komen we tot het volgende focus algoritme, die samen de volledige 100% vormen van het uitvalrisico:

- Logingedrag 30%
- Afronding 25%
- Score 20%
- Login regelmaat 10%
- Punctualiteit inleveren 10%
- Reflectie 5%

De onderlinge weging van de indicatoren is een beslissing die wordt genomen op basis van zowel de academische literatuur die hierboven is genoemd als de voorkeuren en praktische overwegingen van docenten in de praktijk.


### Relevante datapunten en indicator algoritme

Een volgende vraag die we ons nu moeten stellen is: welke *relevante datapunten* heb je nodig om zicht te krijgen op de indicatoren? Hierbij is ook relevant welke *data* er überhaupt beschikbaar is, iets waar we al eerder kort naar hebben gekeken en waar men ook vaker naar terugkomt. Dat is namelijk de basis. Zo zagen we dat communicatiedata vaak ontbreekt in onze context, waardoor we communicatie niet als indicator konden meenemen.





Vervolgens kijken we per indicator ook meteen naar: welk *indicator algoritme* zorgt ervoor dat de losse data de juiste betekenis krijgen? Want we hebben onze indicatoren vastgesteld. We stellen nu onze relevante datapunten vast. Hoe bereken je nu met de data precies datgene wat je in indicator te weten wilt komen? Dat doe je met het indicator algoritme: het vormt de brug tussen de data en de indicatoren.



We zullen hieronder per vastgestelde indicator eerst kijken welke beschikbare data we daarvoor hebben en welke datapunten we nodig hebben. Daarna maken we de koppeling met de indicatoren: welk algoritme is nodig om ervoor te zorgen dat de data datgene berekent wat je met deze indicator te weten wilt komen?

Voor de indicator score hebben we als datapunten: alle scores op alle activiteiten waar een score is te behalen – minus de activiteiten die als metadata ‘reflectie’ hebben, omdat die bij een andere indicator terecht komen. Voor deze indicator beginnen we met een simpeler algoritme: we nemen namelijk simpelweg de gemiddelde score over al deze activiteiten, wat ook betekent dat scores op verschillende schaal worden omgerekend naar een 0-100 schaal (bv. een opdracht waarbij 3 op 10 is gehaald wordt 30 op 100).

Bij reflectie gebruiken we als datapunten: alle scores op alle activiteiten met als metadata ‘reflectie’ waar een score is te behalen. We gebruiken hier eenzelfde indicator algoritme als bij de indicator score: we nemen de gemiddelde score over al deze activiteiten waarbij scores op verschillende schaal worden omgerekend naar een 0-100 schaal.

De datapunten die we bij de indicator afronding kunnen gebruiken zijn: elke afronding op alle activiteiten die gedaan/bekeken/afgerond/ingeleverd kunnen worden. Voor het indicator algoritme geven we per afgeronde activiteit een 100% score, per niet afgeronde activiteit een 0% score. Vervolgens kijken we naar het gemiddelde over alle activiteiten. Dat betekent dat als je van de 10 opdrachten er 8 hebt gedaan je een 80% score op afronding krijgt.

Maar dat is nog niet alles voor de indicator afronding. Want als de totale cursus 10 opdrachten heeft, betekent dit dat je aan het begin van de cursus – als je nog (bijna) geen opdrachten hebt gedaan – maar een paar procent aan afronding zou hebben, waardoor vervolgens je uitvalrisico omhoog zou gaan. Dat is niet juist, want je *hoort* immers nog niet alles gedaan te hebben. Daarom willen we in het indicator algoritme alleen kijken naar de activiteiten *die op dat moment afgerond zouden moeten zijn*. Om te bepalen wat er op dat moment afgerond zou moeten zijn gebruiken we een ander datapunt: de deadline van een activiteit. Dit betekent dat als er 10 activiteiten zijn in de hele cursus waarvan je er in de eerste week twee zou moeten hebben afgerond, dat als je in de eerste week slechts een activiteit hebt afgerond je op dat moment een 50% afrondingsscore krijgt – je hebt namelijk op een activiteit 0% qua afronding en op een andere activiteit 100%, dat delen we door twee = 50%.

Hierbij is het ook mogelijk dat iemand meer heeft afgerond dan op dat moment volgens de planning nodig zou moeten zijn. Strikt bekeken zou iemand dus meer dan 100% afronding kunnen scoren. Dit kan vervolgens ook leiden tot een uitvalrisico hoger dan 100% of lager dan 0%. Aangezien dat onwenselijk is bepalen we in het algoritme ook dat iemand, ook al ronden ze meer af dan op dat moment wordt verwacht, ze wel een hogere afronding kunnen hebben dan 100%, maar dat dit voor de focus (het totale uitvalrisico) nooit voor meer dan 100% meetelt.

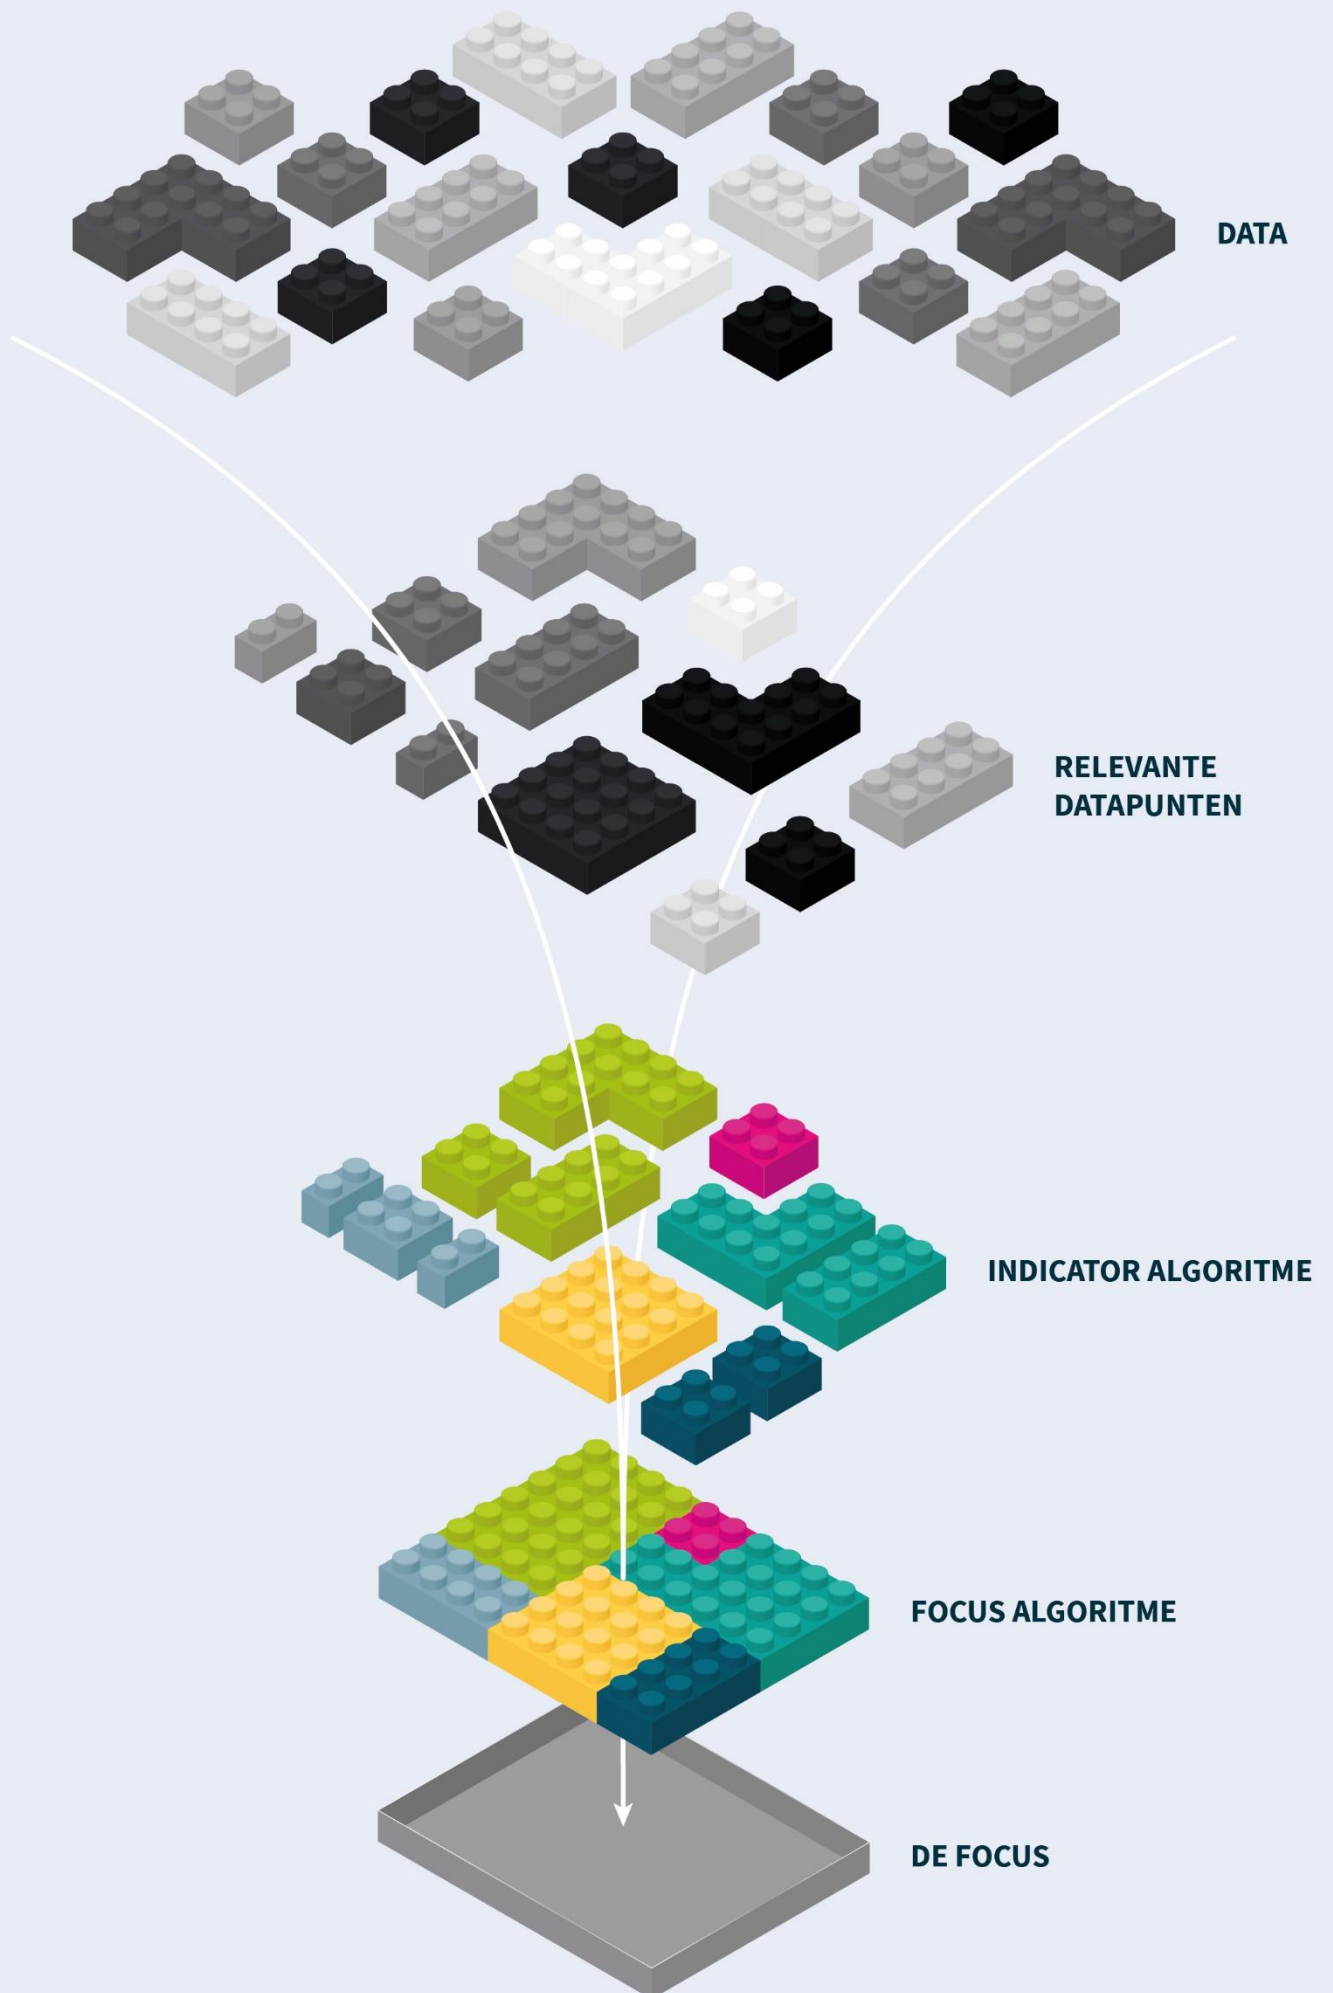
Voor de indicator punctualiteit kijken we naar twee datapunten: ten eerste de ‘timestamp’ van het inlevermoment en ten tweede de deadline van de activiteit. Je hebt deze namelijk allebei nodig om de punctualiteit te kunnen bepalen: was iemand op tijd met inleveren of te laat? Het indicator algoritme ziet er dan als volgt uit: per activiteit krijgt iemand een 100% score als deze op tijd (op of voor de deadline) is ingeleverd en een 0% score als deze te laat (na de deadline) is ingeleverd, waarbij uiteraard alleen kan worden gekeken naar activiteiten die ook daadwerkelijk zijn ingeleverd. Vervolgens wordt de punctualiteitsscore berekend door het gemiddelde over alle activiteiten te nemen.

In de categorie logindata hebben we als eerste datapunt de ‘timestamp’ van het loginmoment. Daarnaast hebben we ook de start- en einddatum van de cursus nodig – zoals bij het indicator algoritme hieronder wordt uitgelegd. We kunnen deze datapunten gebruiken voor zowel de indicator inloggedrag als voor de indicator regelmaat inloggen.

We kijken eerst naar het indicator algoritme voor logingedrag. In dit geval willen we grip krijgen op het gedrag van inloggen: hoe vaak logt iemand in de cursus in? Om dit te berekenen bepalen we (de klant of wij samen met de klant) een norm: hoe vaak wil je dat iemand in een week inlogt. In dit geval zetten we de norm op twee keer per week. Niet te hoog, als iemand elke week een paar keer inlogt is dat voldoende om te weten dat deze persoon meedoet. Voor elke week krijgt de student dan een login score: 100% als zij twee of meer keer inloggen, 50% als ze een keer inloggen, 0% als ze niet inloggen in die week. Vervolgens wordt over alle weken in de cursus tot dan toe – dit is de reden waarom we de start- en einddatum van de cursus nodig hebben, zodat we weten welke weken het betreft – het gemiddelde berekend.

Bij login regelmaat willen we met dezelfde data net iets anders te weten komen: niet zozeer het gedrag qua *aantal* logins, maar eerder qua *spreiding en regelmaat*. Hiervoor kijken we wederom naar de weken in de cursus (gebruik makend van de start- einddatum van de cursus) en geven we een regelmaat score op basis van de variatie of consistentie: als iemand elke week 2 keer inlogt is dat een hoge regelmaat, als iemand de ene week 0 keer inlogt en de volgende week 20 keer is dat een lage regelmaat.

Op deze manier hebben we vastgesteld welke *data* er beschikbaar is, bekeken welke *relevante datapunten* daaruit we nodig hebben om zicht te krijgen op de indicatoren en welke *indicator algoritmes* nodig zijn om te zorgen dat je met de relevante datapunten datgene berekent dat je met de indicator te weten wil komen. In een eerdere stap hadden we al de *indicatoren*, het *focus algoritme* en de *focus* vastgesteld. Op deze wijze hebben we verschillende losse elementen (de data) met behulp van ons recept langzaam in elkaar schoven zodat alle blokjes samen bepalen hoeveel uitvalrisico iemand heeft. Dit is in de afbeelding hieronder gevisualiseerd.



## Datavisualisatie algoritme

Nu het duidelijk is welke relevante datapunten we gebruiken voor welke indicatoren met welke indicator algoritmes en welk focus algoritme we gebruiken om de focus uitvalrisico te berekenen is het tijd voor de laatste stap: het *datavisualisatie algoritme*. Op basis van het recept hebben we namelijk berekend (aan de hand van verschillende indicatoren, gebaseerd op meerdere datapunten) hoeveel uitvalrisico een student heeft. De laatste vraag is: hoe wil je dat uitvalrisico visualiseren? Dit is een belangrijke stap, want je wil dat je data toegankelijk en overzichtelijk is én in één oogopslag duidelijk maakt welke interventies je kunt doen.

Voor uitvalrisico hebben we in eerste instantie gekozen voor een signaallijst: als docent wil je snel in kunnen zien wie er gevaar lopen. Voor de datavisualisatie betekent dit dat we twee kolommen hebben: een lijst met studenten en de tweede de balk die het uitvalrisico per student aangeeft.

Het datavisualisatie algoritme bestaat er dan uit dat elke student een gekleurde balk krijgt op basis van hun uitvalrisico, waarbij geldt hoe hoger het uitvalrisico is hoe groter de balk, met de volgende kleurverdeling:


- 0-20% uitvalrisico: donkergroen
- 20-40% uitvalrisico: lichtgroen
- 40-60% uitvalrisico: oranje
- 60-100% uitvalrisico: rood

We kiezen ervoor om onder de 40% groen te houden, omdat het dan redelijk tot zeer goed gaat. Heb je meer dan 40% dan kom je al dichterbij de gevarencijfer, vandaar dat het vanaf dat punt oranje en rood wordt.



Tegelijkertijd kiezen we er ook voor om in de balkjes geen cijfers weer te geven. De berekening die we in het recept uitvalrisico hebben gemaakt is namelijk slechts een *indicatie*, en nooit een volledig representatieve weergave van iemands uitvalrisico. Iemand kan nooit 100% uitvalrisico hebben, dat zou betekenen dat ze geen kans hebben om de cursus te halen. Het learning analytics recept geeft eerder aan: op basis van deze beschikbare data en berekeningen bestaat de kans dat deze student meer gevaar loopt om uit te vallen. Het is dus vooral relevant om te zien of iemand in de gevarenzone zit – niet zozeer of ze nou 79% of 83% procent uitvalrisico hebben – en dat zie je in één oogopslag aan de grootte en kleuren van de balkjes.

Daarnaast willen we docenten ook kunnen laten zien *waarom* iemand een bepaald uitvalrisico heeft behaald. Daarom bieden we de docenten ook een andere ‘view’ aan. Hierin nemen we geen signaallijst, maar een spinnenweb als basisvisualisatie. In elk punt van het spinnenweb laten we vervolgens de score van een student (en de groep) per indicator zien. Hierbij heeft elke student (en de groep) een eigen kleur lijn. Zoals gezegd uitgelegd kun je technisch gezien meer dan 100% afronden. Daarom is er voor alleen deze indicator een extra lijn waarop studenten komen te staan die meer hebben afgerond dan ze op dat moment volgens de planning hadden gehoeven.



## Verdere overwegingen

Zoals hierboven vaak te zien is geweest zijn de learning analytics recepten enerzijds ontwikkeld aan de hand van academisch onderzoek en anderzijds aan de hand van de praktijk: wat willen docenten weten en welke data is beschikbaar? Het is daarom ook altijd belangrijk om een recept over langere tijd door te ontwikkelen en deze continue in de praktijk te testen. Soms blijkt het namelijk mogelijk om nieuwe belangrijke data (zoals aanwezigheid in de klas) in te zien, dan wil je deze toevoegen aan het recept. Ook kan het voorkomen dat bepaalde indicatoren (bijvoorbeeld waar nog minder onderzoek naar is gedaan) in de praktijk niet zo belangrijk blijken te zijn om uitval aan te geven dan vooraf gedacht. In die gevallen wil je óf je focus algoritme aanpassen en deze indicator voor minder procent laten meetellen in de weging van uitvalrisico, óf deze indicator in zijn geheel uit het recept schrappen.

Daarnaast kan het goed zijn om blijven na te denken over nieuwe mogelijkheden. Het bovenstaande maakte al duidelijk dat dezelfde datapunten, zoals inlogdata, kan leiden tot verschillende indicatoren: we zagen hierboven inloggedrag en inlog regelmaat. Maar er zijn nog meer mogelijkheden die je wellicht kunt onderzoeken. Een voorbeeld daarvan is het onderzoeken van succesvolle leerders: door de inlogmomenten te vergelijken met de prestaties kun je wellicht correlaties leggen tussen de twee. Misschien zijn studenten die vooral in de ochtend aan het werk zijn over het algemeen veel succesvoller dan andere studenten. Of het kan juist zorgen voor optimalisatie per student: waar de ene student vooral gebaat is bij ochtendwerk functioneert de andere beter in de avond.

Dit zijn slechts enkele van de vele mogelijkheden die rond een learning analytics recept bestaan. Het bovenstaande heeft duidelijk gemaakt dat er veel factoren zijn rond zo'n recept die een invloed hebben. Dit kan limitaties met zich meebrengen. Maar het brengt ook – bijna eindeloze – mogelijkheden met zich mee. Een learning analytics recept is dan ook nooit 'af' of definitief, maar – net als de studenten die het moet helpen – juist altijd in ontwikkeling.



## Literatuur

- Atherton, M, Shah, M, Vazquez, J, Griffiths, Z, Jackson, B, & Burgess, C (2017). 'Using learning analytics to assess student engagement and academic outcomes in open access enabling programmes', *Open Learning: The Journal of Open, Distance and e-Learning*, vol. 32, no. 2), pp. 119–136
- Beer, C. Clark, K., & Jones, D. (2010). Indicators of engagement. In C.H. Steel, M.J. Keppell, P. Gerbic & S. Housego (Eds.), *Curriculum, technology & transformation for an unknown future*. Proceedings ascilite Sydney 2010 (pp.75-86).  
<http://ascilite.org.au/conferences/sydney10/procs/Beer-full.pdf>
- Boroujeni, Mina Shirvani, Sharma, Kidziński, Lukasz, Kshitij, Lucignano, Lorenzo, Dillenbourg, Pierre (2016). How to quantify student's regularity? *Conference Paper 11th European Conference on Technology Enhanced Learning (EC-TEL)* At: Lyon (France). September 2016
- Brennan, Amelia, Andras Nemes, Jeevan Pokhrel, Cameron Doyle, Vishesh Jain and David McLay (2020). "Implementing an attrition model at scale". *Presented at LAK 2020 Conference*.
- Dawson, S., Macfadyen, L., & Lockyer, L. (2009). Learning or performance: Predicting drivers of student motivation. Paper presented at the Same places, different spaces. Proceedings ascilite Auckland 2009, Auckland.
- Dawson, S., & McWilliam, E. (2008). Investigating the application of IT generated data as an indicator of learning and teaching performance: Queensland University of Technology and the University of British Columbia.
- Douglas, I., & Alemanne, N. D. (2007). Measuring Student Participation and Effort. Paper presented at the *International Conference on Cognition and Exploratory Learning in Digital Age*, Algarve, Portugal.
- Greller, W, & Drachsler, H (2012), 'Translating learning into numbers: A generic framework for learning analytics', *Journal of Educational Technology & Society*, vol. 15, no. 3, pp. 42–57.  
[jstor.org/stable/jeductechsoci.15.3.42](http://www.jstor.org/stable/jeductechsoci.15.3.42)
- Jivet, I. (2021). "The Dashboard That Loved Me: Designing adaptive learning analytics for self-regulated learning." Proefschrift Open Universiteit.
- Jivet, I. (2016). The Learning Tracker: A Learner Dashboard that Encourages Self-regulation in MOOC Learners. Delft University of Technology
- Jones, David (2009). 'The indicators project identifying effective learning: adoption, activity, grades and external factors'. *The Indicators Project*.  
<https://indicatorsproject.wordpress.com/2009/10/09/the-indicators-project-identifying-effective-learning-adoption-activity-grades-and-external-factors/>
- Jovanovic, J., Mirriahi, N., Gašević, D., Dawson, S. & Pardo, A. (2019). Predictive power of regularity of pre-class activities in a flipped classroom. *Computers & Education*, 134(1), 156–168. Elsevier Ltd. Retrieved October 26, 2021 from <https://www.learntechlib.org/p/208173/>.
- Macfadyen, L., & Dawson, S. (2009). Mining LMS data to develop an "early warning system" for educators: A proof of concept. *Computers & Education* 54 (2010) 588–599.
- Marbouti, F, Diefes-Dux, HA, & Madhavan, K (2016), 'Models for early prediction of at-risk students in a course using standards-based grading', *Computers & Education*, vol. 103, pp. 1–15. [Dx.doi.org/10.1016/j.compedu.2016.09.005](https://doi.org/10.1016/j.compedu.2016.09.005)
- McKenney, S, & Mor, Y (2015), 'Supporting teachers in data-informed educational design', *British Journal of Educational Technology*, vol. 46, no. 2, pp. 265–279. doi:10.1111/bjet.12262
- Morris, L. V., Finnegan, C., & Wu, S. (2005). Tracking student behavior, persistence, and achievement in online courses. *Internet and Higher Education*, 8, 221–231.
- Shukor, Nurbiha A., Zaidatun Tasir, Henny Van der Meijden, Jamalludin Harun (2014). 'A Predictive Model to Evaluate Students' Cognitive Engagement in Online Learning', *Procedia - Social and Behavioral Sciences*, Volume 116, 2014.



- Siemens, G, Dawson, S, & Lynch, G (2013), 'Improving the quality and productivity of the higher education sector: Policy and Strategy for Systems-Level Deployment of Learning Analytics', *Society for Learning Analytics Research for the Australian Office for Learning and Teaching*.
- Siemens, G & Long, P (2011), 'Penetrating the Fog: Analytics in learning and education', *EDUCAUSE Review*, vol. 46, no. 11, pp. 30–41. [er.educause.edu/articles/2011/9/penetratingthe-fog-analytics-in-learning-and-education](http://er.educause.edu/articles/2011/9/penetratingthe-fog-analytics-in-learning-and-education).
- Snijders, Chris (2020), professor at Human-Technology Interaction, Let AI be your teacher (or not). *Presented at Conference of Eindhoven University of Technology (TU/e)*.
- West, Luzeckyj, Searle, Toohey & Price (2018). *The Use of Learning Analytics to Support Improvements in Teaching Practice*. Innovative Research Universities. Melbourne, Australia.